

МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение высшего образования

«МИРЭА – Российский технологический университет» РТУ МИРЭА

ИКБ направление «Киберразведка и противодействие угрозам с применением технологий искусственного интеллекта» 10.04.01

Кафедра КБ-4 «Интеллектуальные системы информационной безопасности»

Практическая работа №4

по дисциплине

«Анализ защищенности систем искусственного интеллекта»

Группа: ББМО-01-22 Выполнил: Некрасов Е.А.

Проверил: Спирин А.А.

1. Установим пакет art

2. Загружаем необходимые библиотеки

```
from __future__ import absolute_import, division, print_function, unicode_literals
import os, sys
from os.path import abspath
module_path = os.path.abspath(os.path.join('...'))
if module_path not in sys.path:
  sys.path.append(module_path)
import warnings
warnings.filterwarnings('ignore')
import tensorflow as tf
tf.compat.v1.disable_eager_execution()
tf.get_logger().setLevel('ERROR')
import tensorflow.keras.backend as k
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense, Flatten, Conv2D, MaxPooling2D, Activation, Dropout
import numpy as np
import matplotlib.pyplot as plt
%matplotlib inline
from art.estimators.classification import KerasClassifier
from art.attacks.poisoning import PoisoningAttackBackdoor, PoisoningAttackCleanLabelBackdoor
from art.attacks.poisoning.perturbations import add_pattern_bd
from art.utils import load_mnist, preprocess, to_categorical
from \ art. defences. trainer \ import \ Adversarial Trainer Madry PGD
```

3. Загружаем датасет MNIST и разделяем его на обучающую и тестовую выборки

```
# загружаем датасет MNIST

(x_raw, y_raw), (x_raw_test, y_raw_test), min_, max_ = load_mnist(raw=True)

# случайная выборка:
n_train = np.shape(x_raw)[0]
num_selection = 10000
random_selection_indices = np.random.choice(n_train, num_selection)
x_raw = x_raw[random_selection_indices]
y_raw = y_raw[random_selection_indices]
```

4. Выполняем отравление данных

```
# отравленные данные
percent_poison = .33
x_train, y_train = preprocess(x_raw, y_raw)
x_train = np.expand_dims(x_train, axis=3)

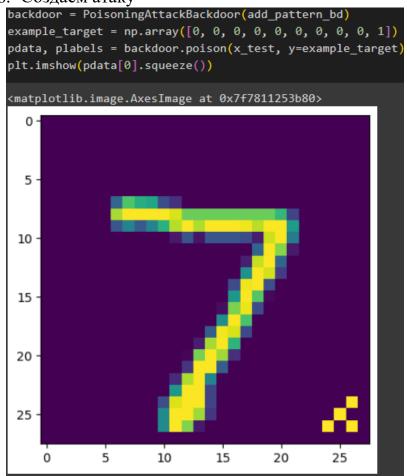
x_test, y_test = preprocess(x_raw_test, y_raw_test)
x_test = np.expand_dims(x_test, axis=3)

# шафл данных
n_train = np.shape(y_train)[0]
shuffled_indices = np.arange(n_train)
np.random.shuffle(shuffled_indices)
x_train = x_train[shuffled_indices]
y_train = y_train[shuffled_indices]
```

5. Пишем функцию create_model() для создания последовательной модели из 9 слоев

```
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense, Flatten, Conv2D, MaxPooling2D, Dropout
def create_model():
   model = Sequential()
   model.add(Conv2D(32, (3, 3), activation='relu', input_shape=(28, 28, 1)))
   model.add(Conv2D(64, (3, 3), activation='relu'))
   model.add(MaxPooling2D(pool_size=(2, 2)))
   model.add(Dropout(0.25))
    # выравнивающий слой
   model.add(Flatten())
   model.add(Dense(128, activation='relu'))
   model.add(Dropout(0.25))
   model.add(Dense(10, activation='softmax'))
    # компиляция
   model.compile(loss='categorical_crossentropy', optimizer='adam', metrics=['accuracy'])
   return model
```

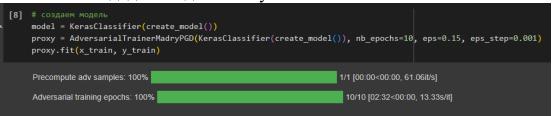
6. Создаем атаку



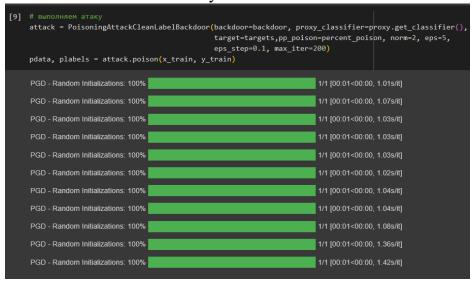
7. Определяем целевой класс атаки

```
# целевой класс атаки
targets = to_categorical([9], 10)[0]
```

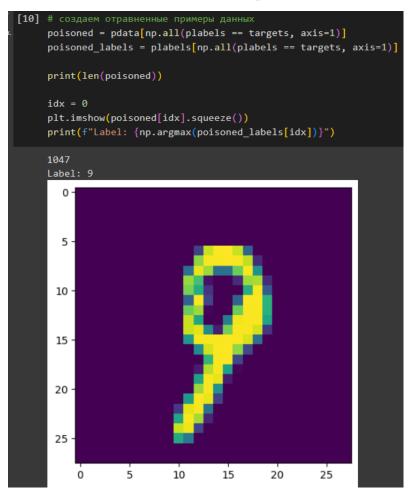
8. Создадим модели и обучим



9. Выполним атаку



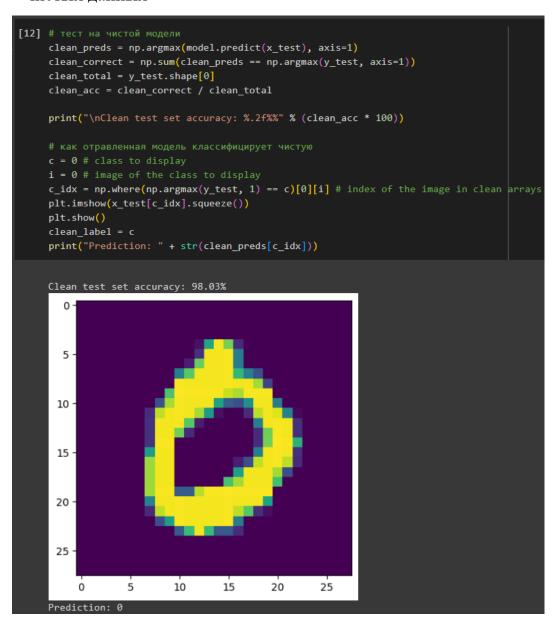
Создадим отравленные примеры данных
 и отобразим одно из отравленных



11. Обучим модель на отравленных данных

```
[11] # обучаем модель на отравленных данных model.fit(pdata, plabels, nb_epochs=10)
```

12.Выполним проверку работы модели в обычных условиях на чистых данных



13. Проверим работу модели на отравленных данных

```
not_target = np.logical_not(np.all(y_test == targets, axis=1))
px_test, py_test = backdoor.poison(x_test[not_target], y_test[not_target])
poison_preds = np.argmax(model.predict(px_test), axis=1)
poison_correct = np.sum(poison_preds == np.argmax(y_test[not_target],
axis=1))
poison_total = poison_preds.shape[0]
poison_acc = poison_correct / poison_total
print("\nPoison test set accuracy: %.2f%%" % (poison_acc * 100))
c = 0 # index to display
plt.imshow(px_test[c].squeeze())
plt.show()
clean_label = c
print("Prediction: " + str(poison_preds[c]))
Poison test set accuracy: 0.60%
  0 -
  5 -
 10 -
 15 -
 20 -
 25 -
     Ó
              5
                      10
                               15
                                       20
                                                25
```